

Double Machine Learning for Causal Inference under Shared-State Interference

Ước lượng hiệu quả tác động đối xử khi các đơn vị tương tác với nhau qua thị trường, hệ thống gợi ý, giá cả, hàng tồn kho, hay các trạng thái chung (shared states) khác.

Chris Hays & Manish Raghavan

Massachusetts Institute of Technology

15/04/2025 · arXiv:2504.08836v1

Hiện tượng Nhiễu loạn (Interference) & SUTVA

Suy luận nhân quả truyền thống giả định **không có nhiễu loạn giữa các đơn vị (no interference / SUTVA)** — giả định này sụp đổ trên nhiều nền tảng thực tế:



Hệ thống gợi ý

Tương tác của một người dùng làm thay đổi nội dung gợi ý cho những người dùng sau



Thị trường / Sàn TMĐT

Khuyến mãi làm thay đổi nhu cầu, giá cả, thời gian chờ và hàng tồn kho




Gọi xe công nghệ

Đối xử với một số hành khách làm thay đổi lượng tài xế trống cho những người khác

Ngay cả *thí nghiệm ngẫu nhiên (randomized experiments)* cũng có thể bị chệch khi một đơn vị được đối xử làm thay đổi điều kiện thị trường chung, ảnh hưởng đến các đơn vị sau. **Di chuột lên từng thẻ để xem trạng thái chung.**

Khái niệm mới: Nhiễu loạn Trạng thái chung (Shared-State Interference)

Nhiễu loạn **không phải tùy tiện** — nó chảy qua một trạng thái chung quan sát được H_t , thứ tóm gọn toàn bộ tác động lan tỏa (spillover) trong quá khứ.



H_t có thể là lượng hàng tồn kho, giá cả, thời gian chờ, điểm phổ biến, hay đầu ra của thuật toán gợi ý — bất kỳ cơ chế nào trung chuyển tác động lan tỏa giữa các đơn vị theo thời gian. Đơn vị vừa *bị ảnh hưởng* bởi trạng thái chung, vừa *góp phần làm thay đổi* nó.

Hạn chế của nghiên cứu trước & Đóng góp của bài báo

NGHIÊN CỨU TRƯỚC ĐÂY

- ▶ Thường dựa vào mô hình **parametric** (tham số cố định)
- ▶ Hoặc giả định đặc thù cho từng bài toán cụ thể
- ▶ Dễ bị chệch khi mô hình hóa sai & khó mở rộng

ĐÓNG GÓP CHÍNH

1. Đưa ra **khung lý thuyết tổng quát (General Framework)** cho SSI.
2. Mở rộng định lý **DML cho SSI** — dùng ML linh hoạt, không cần giả định parametric.
3. Cung cấp **bộ ước lượng phương sai nhất quán (Consistent Variance Estimator)** để xây khoảng tin cậy chuẩn xác.

Điểm mấu chốt: kết hợp được tính linh hoạt của Machine Learning với suy luận thống kê hợp lệ, ngay cả khi dữ liệu phụ thuộc theo chuỗi thời gian.

Thiết lập mô hình toán học (Setting & Notation)

Dữ liệu quan sát tại mỗi bước thời gian $t = 1, 2, \dots, T$:

$$W_t = \{X_t, D_t, H_t, Y_t\}$$

- ▶ X_t : biến nền cảnh (covariates) độc lập đồng phân phối (i.i.d.) — ví dụ vị trí, lịch sử xem, thiết bị
- ▶ D_t : biến đối xử nhị phân (treatment), độc lập với dữ liệu quá khứ nhưng có thể phụ thuộc X_t
- ▶ H_t : trạng thái chung (shared state) quan sát được — biến quyết định của bài báo
- ▶ $Y_t(D_t, H_t)$: kết quả tiềm năng (potential outcome) phụ thuộc *hai* đối số: đối xử của chính đơn vị và trạng thái chung

Khác với SUTVA (kết quả chỉ phụ thuộc D_t), ở đây Y_t bị đồng quyết định bởi cả D_t *lẫn* trạng thái chung H_t . Tồn tại vòng lặp phản hồi hai chiều: $H_t \rightarrow Y_t$, và ngược lại $(D_t, X_t) \rightarrow H_{t+1}$.

Giả định cốt lõi — Tính chất Markov (The Markov Property)

GIẢ ĐỊNH MARKOV CỦA TRẠNG THÁI CHUNG — CÔNG THỨC (1)

$$P(H_t \in A \mid W_{1:t-1}) = P(H_t \in A \mid W_{t-1})$$

Khi đã biết quan sát ngay trước đó W_{t-1} , trạng thái chung kế tiếp H_t độc lập điều kiện với toàn bộ lịch sử xa hơn — "quá khứ xa đã được gói gọn trong hiện tại".

Cấu trúc phụ thuộc (Hình 1): trong sơ đồ ở slide trước, mọi mũi tên từ quá khứ sang tương lai bắt buộc "đi xuyên qua" các nút trạng thái chung $H_{t-1} \rightarrow H_t$. Các cá thể không có mũi tên ngang nối trực tiếp, nhưng ảnh hưởng nhau gián tiếp qua đường trạng thái chung ở tầng trên.

Hệ quả: do X_t i.i.d. và D_t không phụ thuộc quá khứ, toàn chuỗi $\{W_t\}$ tạo thành một **chuỗi Markov thuần nhất (homogeneous Markov chain)** với kernel chuyển trạng thái K_H cố định — nền móng để dùng các định lý giới hạn ở phần sau.

Các điều kiện của Chuỗi Markov (Assumption 2.1)

Hệ thống SSI phải thỏa mãn **một trong hai** cấu trúc phụ thuộc sau:

ĐIỀU KIỆN (A) — HỘI TỤ HÌNH HỌC & CÂN BẰNG CHI TIẾT (GEOMETRIC ERGODICITY & DETAILED BALANCE)

Chuỗi Markov hội tụ về một phân phối dừng duy nhất, với tốc độ cực nhanh theo hàm mũ. Hiểu nôm na: "nhiều phai nhạt nhanh theo hàm mũ" — tương quan giữa các quan sát cách xa nhau giảm về 0 đủ nhanh để suy luận tiệm cận có hiệu lực.

ĐIỀU KIỆN (B) — PHỤ THUỘC HỮU HẠN (M -DEPENDENCE)

Các quan sát cách nhau xa hơn m bước thì hoàn toàn độc lập:

$$W_{1:t} \perp W_{t+m+1:T}$$

Hiểu nôm na: "nhiều chỉ kéo dài tối đa m bước rồi biến mất". Tự nhiên cho các thử nghiệm Switchback.

Hai giả định này *thay thế* giả định i.i.d. trong DML thông thường, cho phép một định lý giới hạn trung tâm (CLT) vẫn đúng trên dữ liệu phụ thuộc.

Tổng quan về Double Machine Learning (DML)

DML cho phép ước lượng các hàm phụ (nuisance) một cách linh hoạt mà vẫn giữ suy luận thống kê hợp lệ.

CÁC HÀM PHỤ (NUISANCE FUNCTIONS)

- ▶ Mô hình kết quả f
- ▶ Điểm xu hướng / propensity score m
- ▶ Các kỳ vọng điều kiện khác được học bằng ML

CƠ CHẾ CỦA DML

- ▶ Số hạng dự báo cắm trực tiếp (plug-in)
- ▶ Số hạng sửa sai (debiasing correction)
- ▶ Trục giao Neyman (Neyman orthogonality) — triệt tiêu sai số bậc nhất của hàm phụ

Bộ ước lượng ML cắm trực tiếp (naive plug-in) bị chệch và hội tụ quá chậm. DML "miễn nhiễm" sai số hàm phụ ở bậc nhất, nhờ đó dùng được các mô hình ML linh hoạt (Random Forest, Gradient Boosting, Neural Network) mà vẫn đạt tốc độ suy luận $\sqrt{T}$.

Thách thức trong SSI: không thể chia mẫu (Sample Splitting) kiểu i.i.d. thông thường vì dữ liệu phụ thuộc chuỗi. Giải pháp: dùng **dữ liệu phụ trợ (Auxiliary Data)** độc lập.

Thuật toán DML cho SSI (Algorithm 1)

BƯỚC 1

Huấn luyện hàm phụ

Học $\hat{\eta} = (\hat{f}, \hat{m})$ trên tập dữ liệu phụ trợ độc lập W^{aux}



BƯỚC 2

Tính bộ ước lượng

$$\hat{\psi} = \frac{1}{T} \sum_{t=1}^T \phi(W_t; \hat{\eta})$$



BƯỚC 3

Ước lượng phương sai

Dùng bộ ước lượng có tính đến phụ thuộc:
batch-means hoặc plug-in tới độ trễ m

Tại sao cần dữ liệu phụ trợ? Chia mẫu (sample-splitting) thông thường không đảm bảo tính độc lập dưới nhiễu loạn trạng thái chung — các phần dữ liệu vẫn "nói chuyện" với nhau qua dòng thời gian.

Tại sao cần trực giao Neyman? Làm $\hat{\psi}$ miễn nhiễm sai số hàm phụ ở bậc nhất $\rightarrow$ suy luận tốc độ $\sqrt{T}$.

Các giả định kỹ thuật — Tính trực giao Neyman (Neyman Orthogonality)

Cơ chế giúp bộ ước lượng "miễn nhiễm" với sai số của các mô hình ML phụ trợ.

ĐẠO HÀM GATEAUX (ĐỊNH NGHĨA A.1)

$$\frac{\partial}{\partial r} f(\eta^* + r(\eta - \eta^*))$$

Đo mức độ nhạy cảm của hàm score khi hàm phụ η bị dịch một chút khỏi giá trị thực η^* .

TRỰC GIAO NEYMAN (ĐỊNH NGHĨA A.2)

$$\frac{\partial}{\partial r} f(\eta^* + r(\eta - \eta^*)) \Big|_{r=0} = 0$$

Đạo hàm Gateaux **bằng 0** tại hàm phụ thực — độ nhạy bậc nhất bị triệt tiêu.

Trực giác: như đứng ở đáy một thung lũng parabol phẳng — bước lệch trái/phải một chút (do ML sai số) thì độ cao (giá trị ước lượng) gần như không đổi. Kết quả: **triệt tiêu sai số bậc nhất (first-order bias cancellation)**, chỉ còn sai số bậc hai nhỏ hơn nhiều và biến mất nhanh khi mẫu tăng.

Định lý chính (Theorem 3.3) & Ước lượng phương sai

ĐỊNH LÝ 3.3 — TÍNH CHUẨN TẮC TIỆM CẬN (ASYMPTOTIC NORMALITY)

Dưới Assumption 2.1 (phụ thuộc chuỗi), trực giao Neyman (3.1) và tốc độ hội tụ hàm phụ (3.2):

$$\sqrt{T} \hat{\sigma}^{-1} (\psi(W_{1:T}; \hat{\eta}) - \psi^*) \Rightarrow N(0, 1)$$

Bộ ước lượng phương sai nhất quán $\hat{\sigma}^2$ — hai trường hợp:

HỘI TỤ HÌNH HỌC (GEOMETRIC ERGODICITY)

Bộ ước lượng kiểu *batch-means* chia chuỗi thành block T_1, T_2 để triệt tiêu hiệp phương sai tích lũy.

M -PHỤ THUỘC (M -DEPENDENCE)

Bộ ước lượng *plug-in mở rộng* với hiệp phương sai tới độ trễ m (dùng cho switchback).

Then chốt: coi H_t như covariate i.i.d. có thể cho cùng một ước lượng điểm, nhưng phương sai sẽ *sai* — bắt buộc phải tính hiệp phương sai theo thời gian, không dùng được công thức cắm (plug-in) i.i.d. thông thường.

Ứng dụng 1 — Tác động Trực tiếp Trung bình (ADE)

Bối cảnh: Dữ liệu quan sát (observational). **Mục tiêu:** đo lường tác động của *một* đơn vị, giữ nguyên phân phối đối xử của các đơn vị khác.

ĐẠI LƯỢNG MỤC TIÊU (ADE)

$$\psi^* = \frac{1}{T} \sum_{t=1}^T \mathbb{E}[Y_t(1, H_t) - Y_t(0, H_t)]$$

Cơ chế: bộ ước lượng dạng AIPW có điều chỉnh theo trạng thái chung H_t :

$$\phi(W_t; \eta) = f(1, X_t, H_t) - f(0, X_t, H_t) + \left(\frac{D_t}{m(X_t)} - \frac{1 - D_t}{1 - m(X_t)} \right) (Y_t - f(D_t, X_t, H_t))$$

Giống AIPW chuẩn, nhưng mô hình kết quả f **chứa** H_t để kiểm soát gây nhiễu. Chi tiết mô hình cấu trúc & Định lý 4.3: xem *Phụ lục*.

Ứng dụng 2 — Thử nghiệm Switchback cho Tác động Toàn cục (GATE)

Bối cảnh: Thử nghiệm Switchback (bật/tắt theo các khối thời gian kế tiếp), nhiễu m -phụ thuộc. **Mục tiêu:** so sánh khi *tất cả* được đối xử vs *tất cả* bị kiểm soát — bao gồm tác động lan tỏa.



ĐẠI LƯỢNG MỤC TIÊU (GATE)

$$\psi^* = \frac{1}{T} \sum_{t=1}^T \mathbb{E}[Y_t(1, H_t(1)) - Y_t(0, H_t(0))]$$

Cơ chế: bộ ước lượng DML kết hợp **Regression Adjustment** (dùng ML dự đoán kết quả từ covariate + trạng thái chung quá khứ, rồi "trừ nhiễu") giúp **giảm đáng kể phương sai** so với switchback truyền thống → tiết kiệm cỡ mẫu. Chi tiết hàm score, cửa sổ thuần nhất & Định lý 5.3: xem *Phụ lục*.

Thực nghiệm cho ADE (Hình 2 & Hình 3)



So sánh năm bộ ước lượng (giá trị tiêu biểu nhất quán với Hình 2–3 của bài báo):



Hai kiểu thất bại: **(1) chệch (bias)** — bỏ qua tác động trạng thái chung làm lệch ước lượng điểm; **(2) KTC không hợp lệ** — bỏ qua hiệp phương sai theo thời gian cho phương sai sai.

Thực nghiệm cho GATE trong Switchback (Hình 4 & Hình 5)

So sánh năm bộ ước lượng (giá trị tiêu biểu nhất quán với Hình 4–6 của bài báo):



Switchback HT chuẩn (Bojinov và cộng sự, 2022) không chệch nhưng KTC **rộng gấp 3–7,5 lần**. DML4SSI đạt độ chính tâm tương đương với phương sai thấp hơn rất nhiều nhờ tận dụng thông tin covariate và trạng thái chung.

Tóm tắt bài thuyết trình

- ▶ Hình thức hóa **hiểu loạn trạng thái chung (SSI)** — một khung cấu trúc hiểu loạn thực tế và khả thi để tính toán.
- ▶ Kết hợp thành công **DML vào chuỗi dữ liệu phụ thuộc Markov** (quan sát phụ thuộc sinh bởi trạng thái chung).
- ▶ Cho bộ ước lượng **chuẩn tắc tiệm cận + phương sai nhất quán** tôn trọng phụ thuộc theo thời gian.
- ▶ Hiện thực hóa cho ADE (quan sát) và GATE (switchback); mô phỏng cho thấy phương pháp này gây thơ bị chệch hoặc KTC không hợp lệ.

THÔNG ĐIỆP CỐT LÕI (TÓM TẮT MỘT CÂU)

Hiểu loạn không làm cho suy luận nhân quả bất khả thi, nếu nó có cấu trúc khai thác được: khi hiểu loạn chảy qua một **trạng thái chung quan sát được**, ta khôi phục được suy luận kiểu DML bằng cách **mô hình hóa sự phụ thuộc** và **ước lượng phương sai đúng cách**.

| Hạn chế & Hướng phát triển tương lai

HẠN CHẾ HIỆN TẠI

- ▶ Yêu cầu trạng thái chung H_t phải **quan sát được**
- ▶ Nhiễu loạn phải được trung chuyển hoàn toàn qua H_t
- ▶ Yêu cầu cấu trúc Markov hoặc m -phụ thuộc
- ▶ Định lý chính dùng dữ liệu phụ trợ để ước lượng hàm phụ

HƯỚNG TƯƠNG LAI

- ▶ Các đại lượng mục tiêu khác: tác động gián tiếp (Average Indirect Effect), tác động chiết khấu theo thời gian
- ▶ Trường hợp trạng thái chung tác động ngược lại lên việc phân bổ đối xử
- ▶ Ứng dụng vào dữ liệu thực tế của các hệ thống khuyến nghị thương mại
- ▶ Kỹ thuật chia mẫu khả thi trên dữ liệu phụ thuộc

Hỏi & Đáp (Q&A)

CẢM ƠN QUÝ VỊ ĐÃ LẮNG NGHE

Rất mong nhận được câu hỏi, nhận xét và góp ý từ quý vị.

DML4SSI: khi nhiễu loạn chảy qua một trạng thái chung quan sát được, ta vẫn có suy luận nhân quả hợp lệ bằng cách mô hình hóa sự phụ thuộc và ước lượng phương sai đúng cách.

| Phụ lục — Nội dung chi tiết & dự phòng

- ▶ ADE — Mô hình cấu trúc · Bộ ước lượng (hàm score) · Định lý 4.3
- ▶ Switchback — Mô hình & Bộ ước lượng · Định lý 5.3
- ▶ Định nghĩa Estimand (ADE / GATE) dạng tab tương tác
- ▶ Chiến lược chứng minh (Proof Strategy)
- ▶ Bảng ký hiệu · Định vị trong nghiên cứu liên quan

ADE — Mô hình cấu trúc

Các phương trình cấu trúc:

$$Y_t(D_t, H_t) = f^*(D_t, X_t, H_t) + \tilde{Y}_t$$

$$H_t(W_{t-1}) = h^*(W_{t-1}) + \tilde{H}_t$$

$$D_t = m^*(X_t) + \tilde{D}_t$$

Đại lượng mục tiêu (ADE):

TÁC ĐỘNG TRỰC TIẾP TRUNG BÌNH

$$\psi^* = \frac{1}{T} \sum_{t=1}^T \mathbb{E}[Y_t(1, H_t) - Y_t(0, H_t)]$$

Chỉ đổi đối xử của đơn vị đang xét. Phân phối phân bổ đối xử của các đơn vị khác giữ nguyên.

ADE — Bộ ước lượng (hàm score)

Số hạng cầm trực tiếp (plug-in) **cộng** số hạng sửa sai (debiasing):

HÀM SCORE $\Phi(W_T, H)$

$$\begin{aligned}\phi(W_t; \eta) &= f(1, X_t, H_t) - f(0, X_t, H_t) \\ &\quad + \left(\frac{D_t}{m(X_t)} - \frac{1 - D_t}{1 - m(X_t)} \right) (Y_t - f(D_t, X_t, H_t))\end{aligned}$$

Các hàm phụ: $\eta = (f, m)$

Trông giống bộ ước lượng AIPW (Augmented Inverse Probability Weighting) chuẩn — chỉ khác ở chỗ mô hình kết quả f **có chứa trạng thái chung** H_t để kiểm soát gây nhiễu. Tuy nhiên suy luận *không phải i.i.d.* vì H_t tạo ra phụ thuộc theo chuỗi thời gian.

ADE — Giả định và Kết quả (Định lý 4.3)

Các yêu cầu chính:

- ▶ Xác suất đối xử bị chặn cách xa 0 và 1 (overlap / positivity)
- ▶ Hàm kết quả và phần dư có moment bị chặn
- ▶ f và m hội tụ theo chuẩn L_2
- ▶ Tích của các sai số hàm phụ là $o_p(T^{-1/2})$

ĐỊNH LÝ 4.3

$$\sqrt{T} \hat{\sigma}^{-1} (\hat{\psi}_{\text{ADE}} - \psi_{\text{ADE}}^*) \Rightarrow N(0, 1)$$

Áp dụng điều kiện "tốc độ tích" (product-rate) quen thuộc của DML: nếu cả hai hàm phụ hội tụ ở tốc độ $T^{-1/4}$ thì tích của chúng đủ nhanh. Nếu propensity score đã biết, mô hình kết quả được phép hội tụ chậm hơn.

Switchback — Mô hình và Bộ ước lượng

Trạng thái chung = m đối xử & covariate ngay trước đó:

$$H_t = \text{vec}(D_{t-m:t-1}, X_{t-m:t-1})$$

HÀM SCORE

$$\begin{aligned} \phi(W_t; \eta) = & f(1, X_t, H_t(1)) - f(0, X_t, H_t(0)) \\ & + \left(\frac{1\{D_{t-m:t}=1\}}{\pi^*(\cdot, 1)} - \frac{1\{D_{t-m:t}=0\}}{\pi^*(\cdot, 0)} \right) \\ & \cdot (Y_t - f(D_t, X_t, H_t)) \end{aligned}$$

Khi nào số hạng sửa sai được kích hoạt?

Toàn chuỗi thời gian →

T T T T | **C C C C** | **T T T**

✓ **Kích hoạt — cửa sổ thuần nhất ($m+1 = 4$)**

T T T T

Cùng một đối xử → kết quả phản ánh chế độ "tất cả được đối xử" → số hạng đóng góp

✗ **Không kích hoạt — cửa sổ pha trộn**

T T C C

Lịch sử pha trộn → không cô lập được chế độ đối xử → bỏ qua số hạng

Switchback — Kết quả (Định lý 5.3)

Các yêu cầu:

- ▶ Xác suất có $m + 1$ quan sát cùng đối xử bị chặn cách xa 0
- ▶ Mô hình kết quả có moment bị chặn
- ▶ Hàm phụ kết quả f hội tụ theo chuẩn L_2
- ▶ Xác suất phân bố đối xử **đã biết** (người làm thí nghiệm kiểm soát việc ngẫu nhiên hóa)

ĐỊNH LÝ 5.3

$$\sqrt{T} \hat{\sigma}^{-1} (\hat{\psi}_{\text{GATE}} - \psi_{\text{GATE}}^*) \Rightarrow N(0, 1)$$

Vì xác suất phân bố đối xử đã biết, hàm phụ duy nhất cần học là mô hình kết quả f .

Các đại lượng mục tiêu (Estimands)

Bài báo nhằm tới các tác động đối xử dưới dạng trung bình dài hạn: $\psi^* = \lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t=1}^T \mathbb{E}[\phi^*(W_t)]$

Tác động Trực tiếp Trung bình (ADE)

Tác động Toàn cục Trung bình (GATE)

Bối cảnh: Nghiên cứu quan sát (observational)

Câu hỏi: Điều gì xảy ra nếu ta đổi đối xử của *một đơn vị*, trong khi giữ nguyên phân phối đối xử của các đơn vị khác?

$$\psi_{ADE}^* = \frac{1}{T} \sum_{t=1}^T \mathbb{E}[Y_t(1, H_t) - Y_t(0, H_t)]$$

Chỉ đổi đối xử của một đơn vị



Các đơn vị khác giữ nguyên mức đối xử tự nhiên

Trạng thái chung H_t tiến hóa theo phân phối đối xử *tự nhiên*

Chiến lược chứng minh

Chứng minh mở rộng lý thuyết DML chuẩn sang dữ liệu phụ thuộc theo bốn bước:

1 Phân rã sai số bộ ước lượng

Tách $\hat{\psi} - \psi^*$ thành: quá trình thực nghiệm oracle + độ lệch hàm phụ + phần dư bậc hai



2 Áp dụng trực giao Neyman

Sai số hàm phụ bậc nhất ~~triệt tiêu về 0~~ → chỉ còn số hạng oracle + phần dư $o_p(T^{-1/2})$



3 Áp dụng CLT cho dữ liệu phụ thuộc

Thay CLT i.i.d. bằng **CLT chuỗi Markov** (geometric ergodicity) hoặc **CLT m -phụ thuộc** để xử lý hiệp phương sai theo thời gian của $\phi(W_t)$



4 Chứng minh tính nhất quán của phương sai

Chứng minh bộ ước lượng batch-means (trường hợp Markov) hoặc plug-in với hiệp phương sai độ trễ m (trường hợp m -dep) hội tụ về phương sai dài hạn thực σ^2

| Bảng ký hiệu chính

- ▶ $W_t = \{X_t, D_t, H_t, Y_t\}$: dữ liệu quan sát tại bước t
- ▶ X_t : biến nền cảnh (covariates)
- ▶ D_t : biến đối xử (treatment)
- ▶ H_t : trạng thái chung (shared state)
- ▶ Y_t : kết quả (outcome)
- ▶ η : các hàm phụ (nuisance functions)
- ▶ f : hồi quy kết quả (outcome regression)
- ▶ m : điểm xu hướng (propensity score)
- ▶ ϕ : hàm score / moment
- ▶ ψ^* : đại lượng mục tiêu
- ▶ $\hat{\psi}$: bộ ước lượng

| Định vị trong các nghiên cứu liên quan

Bài báo kết nối bốn dòng nghiên cứu:

- ▶ **Nhiều loạn trong thị trường và hệ thống gợi ý**
- ▶ **Nhiều loạn kiểu Markov và thử nghiệm switchback**
- ▶ **Suy luận bán tham số (semiparametric) và double machine learning**
- ▶ **Định lý giới hạn trung tâm cho dữ liệu phụ thuộc**

So với nghiên cứu nhiễu loạn mạng lưới (network interference): khung này cho phép mỗi đơn vị phụ thuộc vào nhiều đơn vị trước thông qua một trạng thái chung.

So với mô hình thị trường đặc thù theo lĩnh vực: ít tham số hơn nhưng vẫn cần một quá trình trạng thái có cấu trúc.